

Обнаружение текстов, сгенерированных ИИ

Detection of AI-Generated Text

Автор	Набиль Мухамеш · Магистратура «Прикладной ИИ»
Университет	НИУ ВШЭ — Высшая школа экономики · Москва
Тип работы	Семинарский исследовательский проект
Статус	Планирование / In Progress
Дата	2026

1. ОБОСНОВАНИЕ И АКТУАЛЬНОСТЬ

Широкое распространение крупных языковых моделей (LLM) — GPT-4, LLaMA, Gemini — создаёт растущую угрозу злоупотреблений: академический плагиат, дезинформация, поддельный контент. Автоматическое обнаружение AI-сгенерированных текстов становится критически важной задачей.

Исследование сравнивает классические ML-методы и нейросетевые подходы для бинарной классификации: человеческий текст vs AI-сгенерированный. Помимо этого, проект исследует возможности топологического анализа данных (TDA) как альтернативного подхода, основанного на структурных свойствах языка.

Ключевые исследовательские вопросы

- Какой подход — классический ML (TF-IDF + SVM) или нейросетевой (fastText+LSTM, TinyBERT) — даёт наилучшие результаты?
- Чем различается топологическая сложность AI-текстов и текстов, написанных людьми?
- Применима ли «перфорационная метрика» (Hidden Holes paper) для детектирования AI?
- Как GRU и LSTM ведут себя на задаче детектирования — что лучше улавливает AI-паттерны?
- Можно ли генерировать мягкие метки (soft labels) — оценку уверенности вместо бинарного решения?

2. ТЕОРЕТИЧЕСКАЯ БАЗА

2.1 «Hidden Holes» — Топологический анализ текстов

Статья (Kushnareva et al.) демонстрирует, что тексты, написанные людьми, обладают более высокой топологической сложностью, чем AI-сгенерированные. Для измерения этого используется устойчивая гомология (persistent homology) и комплексы Вьеториса-Рипса.

- Перфорационная метрика («perforation metric»): измеряет число и устойчивость топологических дыр (Betti-числа β_1) в пространстве высокоразмерных эмбедингов
- Ключевой результат: LSTM >> Transformer с точки зрения топологической сложности, что объясняет, почему LSTM-тексты труднее отличить от человеческих
- Практическое применение: вычисление перфорационной метрики как дополнительного признака для классификатора

2.2 «Spot the Bot» — Метод Громова (HSE)

Громов рассматривает язык как самоорганизованную критическую систему — аналог физических систем на пороге фазового перехода. AI-тексты нарушают эту критичность, что проявляется в измеримых статистических аномалиях.

- Размерность Хаусдорфа: фрактальная характеристика текста; у AI-текстов она систематически отличается от человеческих
- Энтропия-сложность (entropy-complexity plane): AI-тексты концентрируются в специфической области этого пространства
- TDA без нейросетей: метод достигает 93–97% точности исключительно на топологических признаках — без обучения нейросети
- Диагностический потенциал: система выявляет стилометрические отклонения и автора-«бота»

2.3 Рекомендации преподавателя

Преподаватель НИУ ВШЭ дал следующие конкретные указания по развитию проекта:

- Пользовательский сценарий: описать конкретные use-cases — студенческие работы, новостные статьи, отзывы
- Качество датасета: обратить особое внимание на качество обучающих данных — garbage in, garbage out
- Статистические и топологические методы: применить TDA наряду с нейросетями
- Baseline: fastText + LSTM — рекомендован как сильный baseline, учитывающий локальный контекст
- Сравнение архитектур: GRU vs LSTM — провести эксперимент
- Продвинутая модель: попробовать TinyBERT — дистиллированный BERT
- Мягкие метки: изобрести метрику уверенности вместо жёсткой бинарной классификации
- TF-IDF: логически не даст высокого результата — включить как низший baseline для подтверждения

3. ПОЛЬЗОВАТЕЛЬСКИЕ СЦЕНАРИИ

Согласно указанию преподавателя, необходимо чётко определить, кто будет использовать систему и в каких условиях.

Сценарий А: Академическая среда

- Пользователь: преподаватель, ассистент кафедры, антиплагиатная система
- Вход: студенческое эссе, курсовая или семинарская работа
- Выход: вероятность AI-генерации + highlighted фрагменты с высокой уверенностью
- Требования: высокий recall (лучше ложная тревога, чем пропуск AI-текста)

Сценарий В: Медиа и верификация фактов

- Пользователь: редактор, fact-checker, платформа публикации

- Вход: новостная статья, пресс-релиз, пост в социальных сетях
- Выход: оценка достоверности + источник (human / AI / mixed)
- Требования: высокая precision, объяснимость решения

Сценарий С: Платформы отзывов

- Пользователь: маркетплейс, сервис отзывов (e-commerce)
- Вход: отзыв на товар или услугу
- Выход: флаг «подозрительный отзыв» + confidence score
- Требования: скорость работы, возможность batch-обработки

4. ДАННЫЕ

4.1 Источники датасетов

- HC3 (Human ChatGPT Comparison Corpus) — пары вопрос-ответ: человек и ChatGPT
- TuringBench — бенчмарк для детектирования AI-текстов
- RAID Dataset — многоисточниковый датасет разных LLM
- AuTextification (IberLEF 2023) — многоязычный, включая испанский
- Сборные данные Reddit / Wikipedia — человеческий текст-эталон

4.2 Требования к качеству

Преподаватель особо подчеркнул: качество датасета критично — «garbage in, garbage out».

- Баланс классов: ~50/50 human vs AI (или применение взвешивания классов)
- Разнообразие доменов: академические тексты, новости, форумы, отзывы
- Разнообразие моделей: GPT-3.5, GPT-4, LLaMA, Claude — разные «авторы»
- Удаление дубликатов, шумовых записей, неразмеченных образцов
- Стратифицированное разбиение: train / validation / test (70 / 15 / 15)

4.3 Предобработка

- Токенизация: стандартная (NLTK / SpaCy) для ML, subword tokenization (BPE) для нейросетей
- Удаление HTML, спецсимволов, нормализация пробелов
- Для TDA: построение эмбедингов → Vietoris-Rips комплексы → вычисление Betti-чисел

5. МОДЕЛИ И АРХИТЕКТУРЫ

Проект включает сравнительный анализ пяти подходов — от простого baseline до топологических методов:

Модель	Тип	Сложность	Обоснование
TF-IDF + SVM	Classical ML (baseline)	Низкая	Стандартный baseline; логически не даст высоких результатов (замечание преподавателя)
fastText + LSTM	Гибридный (слова + посл.)	Средняя	Рекомендован преподавателем как сильный baseline — учитывает локальный контекст

Модель	Тип	Сложность	Обоснование
GRU vs LSTM	Сравнение RNN-архитектур	Средняя	Эксперимент: какая рекуррентная сеть лучше улавливает AI-паттерны?
TinyBERT	Transformer (дистилляция)	Высокая	Контекстуальные эмбединги; ожидаемый лидер по F1
TDA Pipeline	Топологический анализ	Экспер.	Perforation metric + Betti numbers (Hidden Holes paper)

5.1 fastText + LSTM — основной baseline

Рекомендован преподавателем как сильный baseline. fastText даёт качественные word embeddings с учётом морфологии (важно для русскоязычных текстов). LSTM улавливает последовательные зависимости и локальный контекст — ключевые для детектирования AI-паттернов.

- Входные данные: fastText embeddings (dim 300) + LSTM (hidden 256) + Dropout + Dense(2)
- Обучение: Adam optimizer, lr=1e-3, batch_size=64, early stopping
- Soft labels: выходной слой sigmoid + threshold tuning для confidence score

5.2 GRU vs LSTM — сравнительный эксперимент

Цель: выяснить, какая рекуррентная архитектура лучше моделирует AI-паттерны в тексте.

- GRU: меньше параметров, быстрее обучается, иногда лучше работает на коротких текстах
- LSTM: дольше удерживает долгосрочные зависимости — предпочтительно для длинных текстов
- Эксперимент: идентичная архитектура, одинаковые данные — только GRU vs LSTM ячейки
- Метрики: F1, AUC, время обучения, количество параметров

5.3 TinyBERT — продвинутый подход

Дистиллированная версия BERT — в 7.5 раз меньше и в 9 раз быстрее, при сохранении ~97% качества. Контекстуальные эмбединги — ожидаемый лидер по F1.

- Fine-tuning: huggingface/tiny-bert-for-sequence-classification
- Batch size: 16–32, lr=2e-5, 3–5 эпох, linear warmup
- Возможность zero-shot и few-shot детектирования

6. МЯГКИЕ МЕТКИ И МЕТРИКА УВЕРЕННОСТИ

По указанию преподавателя: необходимо «изобрести» метрику уверенности вместо жёсткой бинарной классификации. AI-тексты часто содержат смешанный контент — человек редактировал AI-вывод. Мягкая оценка информативнее бинарной метки.

Предлагаемые подходы

- Model Confidence Score: вероятность из softmax ($P(AI) \in [0, 1]$) — простой baseline
- Ensemble Agreement: доля моделей ансамбля, предсказавших AI — интерпретируемая метрика

- Sentence-Level Score: оценка каждого предложения отдельно → агрегация (mean, max) → mixed-content detection
- Topological Confidence: нормированная перфорационная метрика как мера «похожести на AI»
- Calibrated Probability: temperature scaling для калибровки вероятностей нейросети

Итоговый confidence score — взвешенная комбинация: модельная уверенность (0.5) + топологический показатель (0.3) + лингвистические признаки (0.2).

7. МЕТРИКИ ОЦЕНКИ

Метрика	Описание	Почему важна
Accuracy	Доля верных предсказаний	Базовый показатель
F1-Score	Гармоническое среднее точности и полноты	Учитывает дисбаланс классов
ROC-AUC	Площадь под кривой ROC	Устойчивость к порогу классификации
Confidence Score	Уверенность модели в предсказании (0–1)	Мягкие метки — ключевая задача
Topological Complexity	Число дыр (Betti-числа) в данных	Distinguishes human vs AI structure
Hausdorff Dimension	Фрактальная размерность текста	Критерий самоорганизованной критичности

8. ПЛАН РАБОТ ПО ФАЗАМ

Phase 1: Подготовка данных и EDA · 2–3 недели

- Сбор и объединение датасетов (HC3, TuringBench, RAID)
- Анализ распределения классов, доменов, длин текстов
- Предобработка: токенизация, очистка, нормализация
- Стратифицированное разбиение train/val/test
- Анализ качества: удаление дубликатов, шумовых примеров

Phase 2: Baseline: TF-IDF + Classical ML · 1–2 недели

- Векторизация TF-IDF (unigrams + bigrams)
- Обучение SVM, Logistic Regression, Random Forest
- Оценка Accuracy, F1, AUC — ожидаемо невысокие результаты
- Документирование как нижней границы качества

Phase 3: Neural Baselines: fastText + LSTM/GRU · 2–3 недели

- Обучение fastText embeddings на данных (или предобученные)
- Построение LSTM-классификатора с dropout и early stopping
- Параллельно: идентичная архитектура на GRU
- Сравнение GRU vs LSTM: F1, AUC, время, параметры
- Реализация confidence score (softmax + threshold tuning)

Phase 4: TinyBERT Fine-tuning · 2 недели

- Fine-tuning TinyBERT на задаче бинарной классификации
- Эксперименты с learning rate, batch size, эпохами
- Calibration: temperature scaling для вероятностей
- Sentence-level scoring для mixed-content detection

Phase 5: Топологический анализ (TDA) · 2–3 недели

- Вычисление эмбедингов → Vietoris-Rips комплексы
- Persistent homology: Betti numbers β_0, β_1
- Перфорационная метрика по Hidden Holes paper
- Размерность Хаусдорфа + entropy-complexity (Gromov)
- TDA как standalone классификатор + как дополнительный признак

Phase 6: Сравнение и финальный отчёт · 1–2 недели

- Сводная таблица результатов всех моделей
- Анализ ошибок (confusion matrix, error analysis)
- Реализация финального confidence score (ensemble)
- Написание отчёта + презентация результатов

9. ТЕХНИЧЕСКИЙ СТЕК

Язык и среда	Python 3.11 · Jupyter Notebook · VS Code
ML / DL	scikit-learn · PyTorch · Hugging Face Transformers
NLP	NLTK · SpaCy · fastText · BPE Tokenizer
TDA	Ripser · Gudhi · Persim (persistent homology)
Эксперименты	MLflow · Weights & Biases (tracking)
Данные	Pandas · NumPy · datasets (HuggingFace)
Визуализация	Matplotlib · Seaborn · Plotly
Версии	Git · GitHub · DVC (data versioning)

10. ОЖИДАЕМЫЕ РЕЗУЛЬТАТЫ

По качеству моделей

- TF-IDF + SVM: Accuracy ~70–75%, F1 ~0.68 — подтверждён слабый baseline
- fastText + LSTM: Accuracy ~85–90%, F1 ~0.87 — сильный рекомендованный baseline
- GRU: сопоставим с LSTM, потенциально быстрее на коротких текстах
- TinyBERT: Accuracy ~92–95%, F1 ~0.93 — ожидаемый лидер
- TDA (Gromov-style): Accuracy ~88–93% без нейросетей — новаторский результат

Научный вклад

- Первое сравнение TDA-методов (Hidden Holes + Gromov) с нейросетями на задаче AI-detection
- Разработка интегрированного confidence score на основе ансамбля
- Воспроизведение и проверка перфорационной метрики на новых данных
- Практические рекомендации по выбору подхода для разных сценариев

11. РИСКИ И ОГРАНИЧЕНИЯ

- Дрейф данных: модели обучены на конкретных LLM — новые версии GPT/Claude могут обойти детектор
- Вычислительные ресурсы: TinyBERT требует GPU; TDA — высокая сложность для длинных текстов
- Качество датасетов: сложность верификации, что «человеческий» текст не отредактирован AI
- Мультиязычность: большинство датасетов на английском; русскоязычные тексты — отдельная задача
- Adversarial атаки: paraphrasing, маскировка AI-стиля — устойчивость системы под вопросом

КЛЮЧЕВЫЕ ИСТОЧНИКИ

- [1] Kushnareva et al. «Artificial Text Boundary Detection with Topological Data Analysis» — Hidden Holes paper. Персистентная гомология для обнаружения AI-текстов.
- [2] Gromov A. «Spot the Bot: Language as a Self-Organized Critical System» — НИУ ВШЭ. Размерность Хаусдорфа, энтропия-сложность, TDA без нейросетей (93–97%).
- [3] Guo et al. «How Close is ChatGPT to Human Experts?» — HC3 датасет, baseline для детектирования ChatGPT.
- [4] Jia et al. «TinyBERT: Distilling BERT for Natural Language Understanding» — архитектура TinyBERT.
- [5] Боянков и др. «RAID: A Shared Benchmark for Robust Evaluation of Machine-Generated Text Detectors» — 2023.